

Christian-Albrechts-Universität zu Kiel

09_parametrische_tests

F-Test, t-Test und Anova



Wiederholung: Grundgesamtheit und Stichprobe

G AIG

Christian-Albrechts-Universität zu Kiel

Eigenschaften der Grundgesamtheit: Parameter

Parameter gibt es immer, sie sind feste Werte, aber sie sind unbekannt, meist auch nicht überprüfbar

Bsp: μ : Arithm. Mittel der Grundgesamtheit \bar{x} : Arithm. Mittel der Stichprobe

σ: Standardabweichung der Grundgesamtheit s: Standardabweichung der Stichprobe

In statistischen Tests können immer nur die Eigenschaften der Stichprobe geprüft werden. Daher hängt die Qualität der Aussage immer von der Wahl der Stichprobe ab (Repräsentativität)



Christian-Albrechts-Universität zu Kiel

Parametrische Tests

parametrisch vs. nicht-parametrisch/parameterfrei:

parametrisch: Werte müssen bestimmter Verteilung folgen (z. B. Normalverteilung); Grundannahmen zur Verteilung sind notwendig


nicht-parametrisch: Annahmen zur Werteverteilung entfallen; keine Grundannahmen notwendig

Parametrische Tests, Vorteile - Nachteile:

Vorteil: Haben meist eine größere Power (Teststärke).

Nachteil: Sind nicht anwendbar, wenn keine Aussage über die Verteilung möglich ist oder die Verteilung nicht den für parametrische Tests gegebenen Anforderungen entspricht.

Es können meist keine relativ kleine Stichproben getestet werden.



Mögliche Voraussetzungen für parametrische Tests

CAG

Christian-Albrechts-Universität zu Kiel

Bestimmte Verteilung

Die Daten müssen bestimmten Verteilungen entsprechen, also aus Phänomenen bestimmter Art stammen.

Beispiel: t-Test: Normalverteilung

Bestimmte Ähnlichkeiten

Die Daten müssen einander in bestimmten Parametern gleichen.

Beispiel: Anova: Varianzhomogenität

Bestimmte Skalierungen

Fast immer muss mind. 1 Variable intervallskaliert oder höher sein.


Beispiel F-Test: Test für Varianzen, daher mind. Intervalskaliert (abweichung vom arith. Mittel, dieses nur bei Intervall oder höher skalierten Variablen zu berechnen)



CAU

Christian-Albrechts-Universität zu Kiel

Möglicher Testbaum





Christian-Albrechts-Universität zu Kiel

Prüfen auf Normalverteilung ks.test

Der gute alte Kolmogorv-Smirnov

Möglich, wenn Parameter der Grundgesamtheit bekannt (μ , σ) sind oder approximiert werden können.

```
Bsp. Längen von Silex-Klingen (simuliert) normalverteilt? klingenlaenge<-c(14.9, 24.0, 8.7, 29.3, 25.5, 23.9, 22.4, 12.7, 8.7, 25.1, 25.6, 14.7, 23.0, 23.2, 26.5, 11.1, 15.2, 20.6, 20.1, 25.1)
```

 $\verb|ks.test(klingenlaenge,"pnorm",mean(klingenlaenge)|, sd(klingenlaenge)|)|\\$

One-sample Kolmogorov-Smirnov test

data: klingenlaenge
D = 0.1966, p-value = 0.4221
alternative hypothesis: two-sided

Ergebnis nicht signifikant, Verteilung weicht nicht signifikant von Normalverteilung ab.

Aber: K-S-Test ist sehr konservativ, null-hypothese (gleichverteilung) wird nur abgelehnt, wenn sehr deutliche Unterschiede existieren.



Prüfen auf Normalverteilung shapiro.test

CAIG

Christian-Albrechts-Universität zu Kiel

Der bessere Test auf Normalverteilung

Voraussetzungen: X₁, . . . , X_n ist unabhängige Stichprobe metrisch einer skalierter Variabe

H₀: die Grundgesamtheit ist normalverteilt

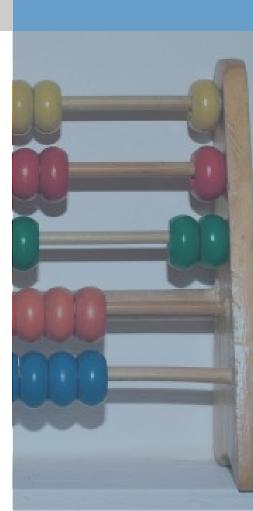
H₁: die Grundgesamtheit ist nicht normalverteilt

> shapiro.test(klingenlaenge)

Shapiro-Wilk normality test

data: klingenlaenge
W = 0.902, p-value = 0.04494

Aber: t-Test ist relativ robust, eine Nicht-Ablehnung durch den ks.test reicht eigentlich aus (bei größeren n-Werten).




Christian-Albrechts-Universität zu Kiel

Prüfen auf Normalverteilung QQ-Plot

Graphische Kontrolle auf Normalverteilung

Abtrag der Quantile der Verteilung gegen die Quantile einer Normalverteilung

- > qqnorm(klingenlaenge)
- > qqline(klingenlaenge)





Christian-Albrechts-Universität zu Kiel

Aufgabe Prüfen auf Normalverteilung

Henkellängen von Amphoren der Dresseltypen 10 (Ihm 1978)

Gegeben sind die Henkellängen verschiedener Amphoren. Stellen Sie mit allen Ihnen zur Verfügung stehenden Mitteln fest, ob diese normalverteilt sind.

File: henkel_amphoren.csv



Christian-Albrechts-Universität zu Kiel

Lösung Prüfen auf Normalverteilung


Henkellängen von Amphoren der Dresseltypen 10 (Ihm 1978)

Gegeben sind die Henkellängen verschiedener Amphoren. Stellen Sie mit allen Ihnen zur Verfügung stehenden Mitteln fest, ob diese normalverteilt sind.

File: henkel_amphoren.csv

```
> henkel<-read.csv2("henkel_amphoren.csv",row.names=1)
> shapiro.test(henkel$henkellaenge)
...
W = 0.8849, p-value = 0.02174
>
ks.test(henkel$henkellaenge,"pnorm",mean(henkel$henkellaenge),sd(henkel$henkellaenge))
...
D = 0.1542, p-value = 0.7286
...
> qqnorm(henkel$henkellaenge)
> qqline(henkel$henkellaenge)
```

Nach ks.test normal, nach shapiro nicht. QQ zeigt zwei Ausreißer an den Enden.







F-Test

F-Test [1]

Test auf Varianzgleichheit zweier Stichproben

Voraussetzungen: zwei unabhängig normalverteilte Stichproben H₀: Beide Stichproben haben die gleiche Varianz (Streuung).

H₁: Eine Stichprobe hat eine größere Varianz (Streuung).

Idee: Wenn Varianzen gleich sind, müßte ihr Quotient 1 betragen.

$$s_1^2 = s_2^2$$
; dann $\frac{s_1^2}{s_2^2} = 1$

Der Quotient wird mit nach Anzahl von Freiheitsgraden ($df_1=n_1-1$, $df_2=n_2-1$) und gewünschtem Signifikanzlevel mit einer Tabelle F-verteilter Werte verglichen (z.B. Shennan). Wenn der errechnete Quotient > Grenzwert, dann muß die H_0 verworfen werden, sonst ist sie beizubehalten.

Signifikant: ungleiche Varianzen Nicht signifikant: es kann von gleichen Varianzen ausgegangen werden



Christian-Albrechts-Universität zu Kiel

F-Test [2]

Beispiel: Klingenlänge zweier Fundstellen, Berechnung von Hand

n Fundstelle 1 = 20; \bar{x} *Fundstelle* 1 = 20.015

Varianz Fundstelle
$$1 = \frac{\sum_{i=1}^{n} (x_i - \overline{x})^2}{n-1} = \frac{\sum_{i=1}^{20} (x_i - 20.015)^2}{20 - 1} = 40.20871$$

n Fundstelle 2 = 25; \bar{x} *Fundstelle* 2 = 20.492

Varianz Fundstelle
$$1 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{n-1} = \frac{\sum_{i=1}^{20} (x_i - 20,492)^2}{20-1} = 33.0641$$

$$F = \frac{s_1^2}{s_2^2} = \frac{40.20871}{33.0641} = 1,216083607$$

$$df_1 = 20 - 1 = 19, df_2 = 25 - 1 = 24$$
; Sign.level = 0.05

Grenzwert bei df $_{1}$ =19, df $_{2}$ =24, α =0.05:2.114

 $1,\!216083607 <\! 2.114, nicht \ signifikant \ , die \ Varianzen \ unterscheiden \ sich \ nicht \ signifikant \ von ein ander$



Christian-Albrechts-Universität zu Kiel

F-Test [3]

F-Test in R

```
> var.test(laenge~fundort,data=klingenlaenge)
    F test to compare two variances

data: laenge by fundort
F = 1.2161, num df = 19, denom df = 24, p-value = 0.643
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
    0.5185518 2.9822271
sample estimates:
ratio of variances
    1.216084
```

> klingenlaenge <- read.csv2("klingenlaengen.csv",row.names=1)</pre>

Ergebnis nicht signifikant, Varianzen unterscheiden sich nicht signifikant voneinander



Christian-Albrechts-Universität zu Kiel

Aufgabe F-Test

(logarithmierte) Größe von zeremoniellen Erdwerken auf den Gesellschaftsinseln (Beispiel nach Shennan)

Gegeben sind die (logarithmierten) Größen von zeremoniellen Erdwerken in zwei verschiedenen Tälern auf den Gesellschaftsinseln. Stellen Sie fest, ob die Varianzen in beiden Tälern als gleich anzusehen sind!

File: marae.csv



Christian-Albrechts-Universität zu Kiel

Aufgabe F-Test

(logarithmierte) Größe von zeremoniellen Erdwerken auf den Gesellschaftsinseln (Beispiel nach Shennan)

Gegeben sind die (logarithmierten) Größen von zeremoniellen Erdwerken in zwei verschiedenen Tälern auf den Gesellschaftsinseln. Stellen Sie fest, ob die Varianzen in beiden Tälern als gleich anzusehen sind!

```
File: marae.csv
```

> marae<-read.csv2("marae.csv")
> var.test(groesse~tal,data=marae)

```
data: groesse by tal

F = 1.4132, num df = 13, denom df = 9, p-value = 0.6124

alternative hypothesis: true ratio of variances is not equal to 1

95 percent confidence interval:
    0.3689233    4.6805505

sample estimates:
ratio of variances
    1.413196

Die Varianzen sind als gleich anzusehen!
```



T-Test

t-Test, gleiche Varianzen [1]

Test für den Vergleich der Mittelwerte zweier Stichproben

Wenn die Mittelwerte sich signifikant unterscheiden, stammen die Stichproben von unterschiedlichen Populationen


Voraussetzungen: zwei unabhängig normalverteilte Stichproben mit gleicher Varianz

H₀: Die Populationen beider Stichproben haben gleichen Mittelwert


H₁: Die Populationen beider Stichproben haben verschiedenen Mittelwert

Idee: Wenn die Mittelwerte zweier Stichproben innerhalb des Standard-Fehlers der Schätzungen der Differenz der Mittelwerte der zugehörigen Populationen liegen, dann können beide Populationen gleich sein, sonst nicht.









t-Test, gleiche Varianzen [2]

Beispiel: Klingenlänge zweier Fundstellen, Berechnung von Hand

$$n Fundstelle \ 1 = 20 \ ; \ \bar{x} \ Fundstelle \ 1 = 20.015 \ ; \ s_1^2 = 40.20871$$

$$n Fundstelle \ 2 = 25 \ ; \ \bar{x} \ Fundstelle \ 2 = 20.492 \ s_2^2 \ 33.0641$$

$$t = \frac{\bar{x_1} - \bar{x_2}}{s_{x_1 - x_2}}$$

$$s_{\bar{x_1} - \bar{x_2}} = \sqrt{\frac{(n_1 - 1) * s_1^1 + (n_2 - 1) * s_2^2}{n_1 + n_2 - 2}} * \sqrt{\frac{n_1 + n_2}{n_1 * n_2}} = \sqrt{\frac{(20 - 1) * 40.20871 + (25 - 1) * 33.0641}{20 + 25 - 2}} * \sqrt{\frac{20 + 25}{20 * 25}}$$

$$s_{\bar{x_1} - \bar{x_2}} = \sqrt{\frac{1557,50389}{43}} * \sqrt{\frac{45}{500}} = \sqrt{36,221020698} * \sqrt{0,09} = 1,805517062$$

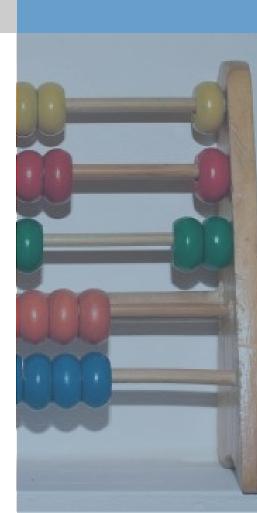
$$t = \frac{20.015 - 20.492}{1,805517062} = -0,264190248$$

$$df = (n_1 - 1) + (n_2 - 1) = n_1 + n_2 - 2 = 20 + 25 - 2 = 43$$
Nachschlagen in Tabelle (z. B. Shennan): df = 43: Sign level = 0.05:

Nachschlagen in Tabelle (z.B. Shennan): df = 43; Sign.level = 0.05; Mögliche Unterschiede: größer-kleiner, daher 2-seitige Fragestellung Grenzwert = 2.021

-0.264190248 < 2.021

nicht signifikant, Null – Hypothese kann nicht abgelehnt werden Es besteht kein signifikanter Unterschied zwischen den beiden Stichproben bezüglich der Mittelwerte, sie könnten aus der gleichen Population stammen!



t-Test, gleiche Varianzen [3]

Test für den Vergleich der Mittelwerte zweier Stichproben

Wenn die Mittelwerte sich signifikant unterscheiden, stammen die Stichproben von unterschiedlichen Populationen

Voraussetzungen: zwei unabhängig normalverteilte Stichproben mit gleicher Varianz

H_o: Die Populationen beider Stichproben haben gleichen Mittelwert


H₁: Die Populationen beider Stichproben haben verschiedenen Mittelwert

```
> t.test(laenge~fundort,data=klingenlaenge,var.equal=T)
```

Two Sample t-test

Kein Signifikantes Ergebnis, die beiden Stichproben unterscheiden sich nicht signifikant hinsichtlich ihrer Mittelwerte.





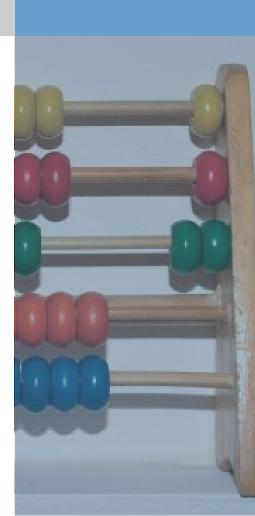
Christian-Albrechts-Universität zu Kiel

Aufgabe t-Test

(logarithmierte) Größe von zeremoniellen Erdwerken auf den Gesellschaftsinseln (Beispiel nach Shennan)

Gegeben sind wiederum die (logarithmierten) Größen von zeremoniellen Erdwerken in zwei verschiedenen Tälern auf den Gesellschaftsinseln. Stellen Sie fest, ob sich die Mittelwerte signifikant unterscheiden!

File: marae.csv



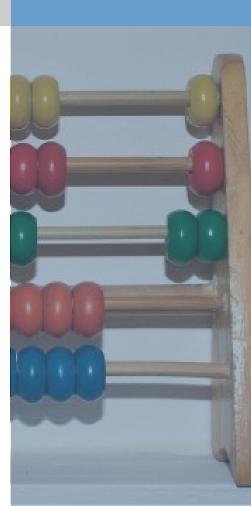
Aufgabe t-Test

(logarithmierte) Größe von zeremoniellen Erdwerken auf den Gesellschaftsinseln (Beispiel nach Shennan)

Gegeben sind wiederum die (logarithmierten) Größen von zeremoniellen Erdwerken in zwei verschiedenen Tälern auf den Gesellschaftsinseln. Stellen Sie fest, ob sich die Mittelwerte signifikant unterscheiden!

```
File: marae.csv
```





Welch-Test (t-Test für ungleiche Varianzen mit Welch-Korrektur)


Wenn die Gleichheitsvoraussetzung nicht erfüllt ist

Annährung der Ergebnisse durch Korrektur der Freiheitsgrade

> klingenlaenge3<-read.csv2("klingenlaenge3.csv",row.names=1)</pre>

```
var.test(klingenlaenge3$x,klingenlaenge$laenge[klingenlaenge$fundort
=="site1"])
F = 0.3535, num df = 19, denom df = 19, p-value = 0.02854
t.test(klingenlaenge3,klingenlaenge$laenge[klingenlaenge$fundort=="s
ite1"],var.equal=F)
    Welch Two Sample t-test
data: klingenlaenge3 and klingenlaenge$laenge[klingenlaenge$fundort
== "site1"1
t = 1.8368, df = 30.941, p-value = 0.07586
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -0.3346190 6.3946190
sample estimates:
mean of x mean of y
   23.045
             20.015
```





Wiederholung: Unabhängige – Abhängige Stichprobe

Abhängige Stichproben:

Das Ergebnis der einen Stichprobe ist teilweise von der anderen abhängig (Untersuchung von Patienten vor/nach Einnahme eines Medikamentes)

```
t.test(variable1,variable2,var.equal=F,paired=T)
Oder
```

t.test(variable1,variable2,var.equal=T,paired=T)

Unabhängige Stichproben:

Das Ergebnis der einen Stichprobe ist nicht von der anderen abhängig (Untersuchung von zwei Gräberfeldern)

```
t.test(variable1,variable2,var.equal=F)
Oder
```

t.test(variable1,variable2,var.equal=T)





Aufnahme und statistische Auswertung archäologischer Daten

Multiples Testen [1]

Das folgende trifft auf alles statistischen Tests zu! Was, wenn man mehr als zwei Gruppen vergleichen will?

Gegeben sind hypothetische Größen von TRB-Siedlungen in Schleswig-Holstein nach Feuchtigkeit des Gebietes und Region.

Frage: Unterscheiden sich die Siedlungsgrößen signifikant je nachdem, wie feucht der Untergrund ist?

Wie ist vorzugehen?



Aufnahme und statistische Auswertung archäologischer Daten

Multiples Testen [2]

Wohl intuitive, aber falsche Lösung!

Man testet die verschiedenen Gruppen jeweils miteinander, ob es einen statistisch signifikanten Unterschied gibt.

Problem: Je öfter man testet, um so höher wird die Wahrscheinlichkeit, das ein signifikantes Ergebnis "per Zufall" entsteht.

Beispiel: Wir testen 3 Gruppen gegeneinander, brauche dazu 3 Tests: Rest ↔ Arid, Rest ↔ Medium, Rest ↔ Humid

Die Wahrscheinlichkeit, dass die Alternativhypothese trotz signifikantem Ergebnis falsch ist, liegt bei jedem Test bei 0.05 %. Das ergibt bei 3 Tests eine Fehlerwahrscheinlichkeit von 3*0,05=0,15%.

Bei 100 Tests wären 5 Tests wahrscheinlich falsch signifikant!



Aufnahme und statistische Auswertung archäologischer Daten

Multiples Testen [3]

Lösungsmöglichkeit 1 (kann auch für alle anderen Tests verwand werden): Korrektur der p-Werte, z.B. Bonferroni-Korrektur

Da die gesamte Prozedur als ein Test aufgefasst werden muss: Teilen der Signifkanzschwelle für die Einzeltests durch Anzahl der Tests ergibt globales Signifikanzniveau für jeden Test.

Beispiel: Vergleichen wir 3 Gruppen miteinander, werden 3 Tests durchgeführt. Signifikant werden nur die p-Werte gewertet, die kleiner als 0.05/3=0,016666667 oder niedriger ausfallen.

t-Test

Medium \leftrightarrow Humid : p-Wert = 0.287 Humid \leftrightarrow Arid: p-Wert = 1.939e-07 Arid \leftrightarrow Medium: p-Wert = 3.436e-05

> p.adjust(c(0.287,1.939e-07,3.436e-05),method="bonferroni")
[1] 8.6100e-01 5.8170e-07 1.0308e-04

Das erste Ergebnis ist bei drei Tests nicht signifikant.





nach



ANOVA

ANOVA [1]

Lösungsmöglichkeit 2 für den t-Test

Vergleich von mehreren Gruppen miteinander

Abhängige Variable: die zu testende Größe (hier size) Unabhängige Variable: die zu testende Gruppierungsvariable (hier wetness)

Graphische Darstellung:

> boxplot(size~wetness, data=settlements)

ANOVA

Es gibt signifikante Unterschiede, nur wo?





CAIU

Christian-Albrechts-Universität zu Kiel

ANOVA [2]

Detaillierte Darstellung der Unterschiede

Zur umfassenden Ausgabe wird der Datensatz als lineares Modell aufgefasst:

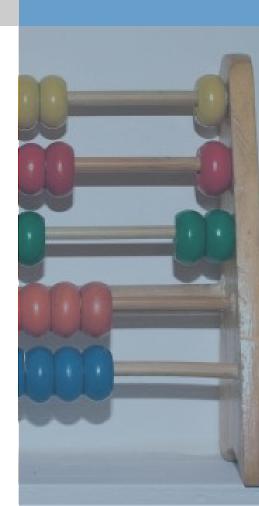
```
> summary.lm(aov(size~wetness, data=settlements))
...
```

Coefficients:

```
Estimate Std. Error t value Pr(>|t|)
(Intercept) 9.388 2.267 4.141 0.000163 ***
wetnesshumid 20.387 3.206 6.359 1.21e-07 ***
wetnessmedium 16.880 3.206 5.265 4.48e-06 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 8.78 on 42 degrees of freedom Multiple R-squared: 0.524, Adjusted R-squared: 0.5013 F-statistic: 23.12 on 2 and 42 DF, p-value: 1.697e-07

Die erste Gruppe (arid) wird als Kontrollgruppe aufgefasst, die anderen Gruppen werden hiermit verglichen. Uns interessiert, wie feuchte und trockene Böden sich von mittelfeuchten Böden unterscheiden, daher muß die Kontrollgruppe auf medium umgestellt werden.



Christian-Albrechts-Universität zu Kiel

ANOVA [3]

Definieren der Kontrollgruppe

Umstellen der Kontrollgruppe (Referenz) auf mittelfeuchte Böden:

```
> wetness.new<-relevel(settlements$wetness, ref ="medium")
> summary.lm(aov(settlements$size~wetness.new))
```

Coefficients:

```
Estimate Std. Error t value Pr(>|t|)
(Intercept) 26.268 2.267 11.587 1.15e-14 ***
wetness.newarid -16.880 3.206 -5.265 4.48e-06 ***
wetness.newhumid 3.506 3.206 1.094 0.28
```

Ein signifikanter Unterschied besteht zwischen Kontrollgruppe (medium) und ariden Böden. Das ganze auf einen Blick mit multiplen t-Tests:



ANOVA [4]

Zweifaktorielle ANOVA

Wenn der Einfluß zweier Gruppierungen auf die Größe untersucht werden soll. Hier: Siedlungsgröße und Region

Darstellung der Größe je Region:

> boxplot(size~regions, data=settlements)

Darstellung der Beziehungen von Region, Feuchtigkeit und Größe:

> interaction.plot(settlements\$wetness, settlements\$regions,
settlements\$size)

ANOVA:


<pre>> summary(aov(size~wetness*regions, data=settlements))</pre>						
	Df	Sum Sq	Mean Sq	F value	Pr (>F)	
wetness	2	3564	1782.1	29.332	3.08e-06	***
regions	13	1372	105.6	1.738	0.142	
wetness:regions	12	832	69.4	1.142	0.391	
Residuals	17	1033	60.8			
Signif. codes:	0	***/ O.	.001 **/	0.01 *	0.05 \.	0.1

Schreibweise in der Formel:

- *: Die Beziehung der Variablen untereinander wird berücksichtigt
- +: Die Beziehung der Variablen untereinander wird nicht berücksichtigt



Christian-Albrechts-Universität zu Kiel



١ / 1

Christian-Albrechts-Universität zu Kiel

ANOVA [5]

Zweifaktorielle ANOVA

Ergebnis: nur Feuchtigkeit hat signifikanten Einfluß auf Siedlungsgröße, nicht Region und auch nicht kombinierte Effekte von Region und Feuchtigkeit sind signifikant

Detaillierte Ausgabe:

> summary.lm(aov(size~wetness*regions, data=settlements))


Ändern der Kontrollgruppe für die Regionen:

> regions.new<-relevel(settlements\$region, ref ="Herzogtum Lauenburg")

Detailierte Ausgabe:

> summary.lm(aov(size~wetness.new*regions.new, data=settlements))

Ergebnis: Von unserer Kontrollgruppe (mittelfeuchte Böden im Herzogtum Lauenburg) weichen keine anderen Gruppen signifikant ab. Nur die Feuchtigkeit hat einen signifikanten Einfluß auf die Siedlungsgröße, dabei sind nur Siedlungen auf feuchten Böden signifikant unterschiedlich von unserer Kontrollgruppe (mittelfeuchte Böden).



Christian-Albrechts-Universität zu Kiel

ANOVA [6]

Varianten der ANOVA

Einfaktorielle Varianzanalyse

Ein unabhängiger Faktor (Gruppierungsvariable), eine abhängige Variable

Zwei- / mehrfaktorielle Varianzanalyse

Zwei / mehrere unabhängige Faktoren (Gruppierungsvariable), eine abhängige Variable

multivariate Varianzanalyse (MANOVA)

Ein/Zwei/Viele unabhängige Faktoren (Gruppierungsvariable), mehrere abhängige Variable

